

Curso Introductorio para la Categoría Robocup@Home Beginners

Instructores:

Marco Antonio Negrete Villanueva

Luis González Nava


Facultad de Ingeniería, UNAM

Escuela de Invierno de Robótica 2020, Saltillo, México.

- Revisar el hardware necesario para tener un robot de servicio doméstico: sensores y actuadores necesarios.
- Dar un panorama general del software necesario para desarrollar un robot de servicio doméstico.
- Revisar las herramientas disponibles para cubrir las habilidades requeridas en la categoría @Home Beginners:
 - ▶ Navigation stack (planeación de movimientos)
 - ▶ Pocketsphinx (reconocimiento de voz)
 - ▶ Sound Play (para síntesis de voz)
 - ▶ OpenCV (reconocimiento de objetos y rostros)

Su objetivo es el desarrollo de robots de servicio doméstico y está enfocada principalmente en las siguientes áreas:

- Interacción humano-robot
- Navegación en ambientes dinámicos
- Visión computacional y reconocimiento de objetos
- Manipulación de objetos
- Comportamientos adaptables
- Integración de Comportamientos
- Estandarización e integración de sistemas







Esta competencia presenta un desafío introductorio a la categoría de @Home Major, basándose en una etapa de pruebas y una final.

- En la etapa de pruebas se evalúan funcionalidades básicas por separado:
 - ▶ Navegación
 - ▶ Reconocimiento de objetos
 - ▶ Manipulación
 - ▶ Reconocimiento de voz
- La prueba final es una integración de las habilidades anteriores.
- El robot debe ejecutar un comando del tipo “Bring [OBJETO] from [LUGAR]”.

- De preferencia, debe ser omnidireccional
- Turtle Bot (<https://www.turtlebot.com/>)
- Festo Robotino (<https://wiki.openrobotino.org/>)
- DIY: 3 ó 4 motores de corriente directa con ruedas omnidireccionales, 2 tarjetas Roboclaw, baterías de LiPo y chasis de aluminio estructural.





- Se pueden usar sólo cámaras RGB, pero es altamente recomendable tener información de profundidad.
- Kinect (<https://github.com/OpenKinect/libfreenect2>)
- Intel RealSense (<https://github.com/IntelRealSense/librealsense>)
- También se pueden usar cámaras estéreo, pero es mucho más sencillo usar cámaras con luz estructurada.

- Hokuyo (<https://www.hokuyo-aut.jp/>)
- RPLidar (<https://www.robotshop.com/en/slamtec.html>)
- SICK (<https://www.sick.com/ag/en/detection-and-ranging-solutions/2d-lidar-sensors/c/g91900>)
- El paquete http://wiki.ros.org/urg_node facilita su operación.
- Si no se tiene uno, se puede simular a partir de una cámara RGB-D con el paquete http://wiki.ros.org/pointcloud_to_laserscan.

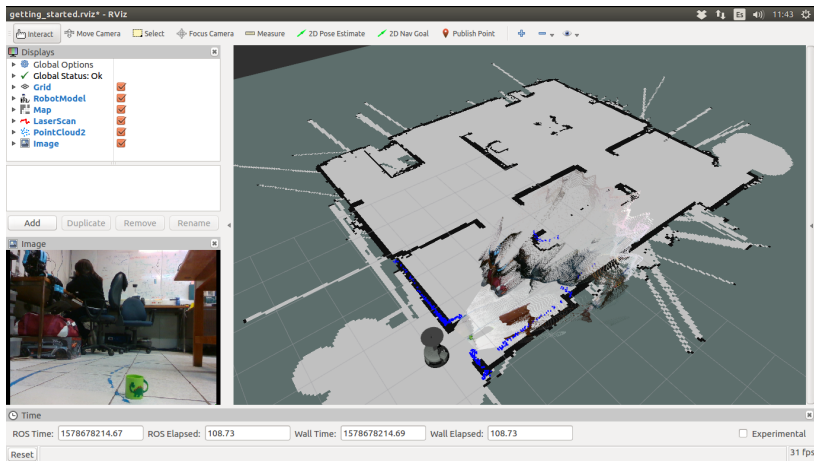




- Son recomendables por lo menos 5 DOF.
- Kuka LBR iiwa
(<http://wiki.ros.org/kuka>)
- Neuronics Katana
(<http://wiki.ros.org/katana>)
- DIY: Servomotores y Brackets Dynamixel
(<http://wiki.ros.org/dynamixel>)

- Se requiere de un marco de referencia absoluto, comúnmente llamado `map`. En Rviz, `map` se selecciona como referencia global.
- La base móvil debe publicar su odometría y aceptar comandos de movimiento.
 - ▶ Para la odometría, debe publicar la transformación de `odom` a `base_link`.
 - ▶ Para los comandos de movimiento, debe suscribirse al tópico `/cmd_vel` de tipo `geometry_msgs/Twist`.
- Se requiere de un nodo que publique la transformación de `odom` a `map`.
 - ▶ Si se está construyendo un mapa, esta transformación la publican paquetes como `gmapping` o `hector-mapping`.
 - ▶ Si ya se tiene un mapa, la transformación la publica el nodo de localización, generalmente `amcl`.
- Se requiere de un archivo que describa la cinemática del robot (archivo `urdf`), es decir, el árbol de transformaciones. Se recomienda que el *frame* raíz tenga el nombre `base_link`. Ejemplo:
`catkin_ws/src/hardware/robot_description/robotino.urdf`
- Cada `joint` del robot corresponderá a una transformación publicada por el nodo `robot_state_publisher`.

Ejecutar el comando `roslaunch bring_up robotino_simul.launch`. Debe aparecer un rviz como el siguiente:




- ❶ Ejecutar el comando `roslaunch tf view_frames` y verificar en el archivo resultante (*frames.pdf*) las transformaciones y qué nodos las publican.
- ❷ Mediante el comando `rostopic info`, desplegar la información de los tópicos `/cmd_vel` , `/scan` y `/camera/depth_registered/points`.
- ❸ Detener la ejecución y modificar el archivo `catkin_ws/src/bring_up/launch/robotino_simul.launch` para cambiar lo siguiente:
 - ▶ La descripción del robot (`robotino.urdf` o `justina_simple.urdf`)
 - ▶ El mapa del ambiente (Universum, Biorobotica o TMR_2019)
- ❹ Modificar el archivo `catkin_ws/src/hardware/robot_description/robotino.urdf` y ver qué sucede cuando:
 - ▶ Se cambian los valores de la etiqueta `origin` en la línea 114.
 - ▶ Se elimina alguno de los campos `<joint>`.



Planeación de rutas.

Encontrar un mapeo:

$$P(\alpha) : [0, 1] \rightarrow Q_{free}$$




Localización: Determinar la configuración $q \in Q$ del robot.



Mapeo: Construir una representación del espacio:

$$Q = Q_{free} \cup Q_{occupied}$$




Cobertura: Mover al robot por todos los puntos $q \in Q_{free}$

Métodos variacionales


Ejemplo:

Suavizado de una ruta



Basados en muestreo



Ejemplo: Rapidly Exploring
Random Trees (RRT)



Búsqueda en grafos

Ejemplos:

Dijkstra y A*



Geométricos

Ejemplo:

Grafo de visibilidad


Filtro de Kalman:

- Con base en un modelo, filtra el ruido de las mediciones de posición.
- Supone que la posición tiene una distribución unimodal (normal).
- Converge sólo si la estimación inicial está cerca de la real.
- El número de estados crece con el número de marcas.
- Bajo costo computacional.



Filtro de Partículas:

- También requiere de un modelo de movimiento.
- La distribución de probabilidad de la posición es multimodal.
- Funciona para cualquier estimación inicial de la posición.
- Cada partícula mantiene una estimación
- Alto costo computacional.



Contiene varios paquetes para planeación de rutas, mapeo, localización y evasión de obstáculos (<http://wiki.ros.org/navigation>). Para este curso se usaron los siguientes:

- `map_server`: Lee el mapa de dos archivos, una imagen `.pgm` y un `yaml` con meta datos. Publica el mapa usando un mensaje de tipo `nav_msgs/OccupancyGrid`.
- `amcl`: Realiza la localización usando el mapa, la odometría y las lecturas del láser. Publica la transformación de `odom` a `map`. `move_base`: Realiza la mayor parte de las tareas de planeación de movimientos, para lo que usa los paquetes:
 - ▶ `dwa_local_planner`
 - ▶ `navfn`
 - ▶ `costmap_2d`

- ❶ Ejecutar los comandos
 - ▶ `roslaunch bring_up robotino_simul.launch`
 - ▶ `roslaunch bring_up navigation_move_base.launch`
- ❷ En el cuadro *Displays* de *Rviz* agregar los tópicos:
 - ▶ `/move_base/DWAPlanerROS/global_plan`
 - ▶ `/move_base/DWAPlanerROS/local_plan`
 - ▶ `/move_base/global_costmap/costmap`
- ❸ Fijar una meta con el botón *2D Nav Goal* y observar el comportamiento.

- ❶ Detener la ejecución de `navigation_move_base.launch`.
- ❷ En el archivo
`catkin_ws/src/config_files/move_base_params/costmap_common_params.yaml`:
 - ▶ Cambiar `cost_scaling_factor` a 1.0
 - ▶ Cambiar `inflation_radius` a 2.5
- ❸ Relanzar `navigation_move_base.launch` y observar qué sucede.
- ❹ Detener la ejecución de `navigation_move_base.launch`.
- ❺ En el archivo
`catkin_ws/src/config_files/move_base_params/dwa_local_planner_params.yaml`:
 - ▶ Cambiar `max_vel_x` a 2.0
 - ▶ Cambiar `max_trans_vel` a 2.0
 - ▶ Cambiar `acc_lim_x` a 2.0
- ❻ Relanzar `navigation_move_base.launch` y observar qué sucede.

Nota: En un robot real, los parámetros anteriores deben ser ligeramente menores a las capacidades físicas de la base móvil.

Pocketsphinx es un *toolkit* open source desarrollado por la Universidad de Carnegie Mellon (<https://cmusphinx.github.io/>).

- Aunque el toolbox original no está hecho específicamente para ROS, ya existen varios repositorios con nodos ya implementados que integran ROS y Pocketsphinx:
 - ▶ <https://github.com/mikeferguson/pocketsphinx>
 - ▶ <https://github.com/Pankaj-Baranwal/pocketsphinx>
- El usuario debe estar agregado al grupo *audio* para el correcto funcionamiento: `sudo usermod -a -G audio <user_name>`
- Se puede hacer reconocimiento usando una lista de palabras, un modelo de lenguaje o una gramática.
- Se utilizarán gramáticas y sus correspondientes diccionarios.
- Para construir diccionarios, visitar <https://cmusphinx.github.io/wiki/tutorialdict/>
- Para construir gramáticas, visitar <https://www.w3.org/TR/2000/NOTE-jsgf-20000605/>

- ➊ Ejecutar el comando `roslaunch bring_up pocketsphinx_test.launch`
- ➋ Verificar los volúmenes del micrófono
- ➌ Revisar el archivo `catkin_ws/src/pocketsphinx/vocab/voice_cmd.gram` para ver las frases que se pueden reconocer de acuerdo con la gramática.
- ➍ Probar el reconocimiento de voz.
- ➎ Detener la ejecución. En el archivo `catkin_ws/src/bring_up/launch/pocketsphinx_test.launch`:
 - ➊ Cambiar el valor del parámetro `gram` de `.../voice_cmd` a `.../restaurant`
 - ➋ Cambiar el valor del parámetro `dict` de `../voice_cmd.dic` a `restaurant.dict`
 - ➌ Cambiar el valor de `grammar` de `voice_cmd` a `restaurant`
 - ➍ Cambiar el valor de `rule` de `move2` a `command`
- ➏ Relanzar el archivo `pocketsphinx_test.launch` y verificar el reconocimiento de acuerdo con la gramática del archivo `restaurant.gram`


- Es un paquete que permite reproducir archivos .wav o .ogg, sonidos predeterminados y síntesis de voz.
- La síntesis de voz se hace utilizando Festival (<http://www.cstr.ed.ac.uk/projects/festival/>).
- Para sintetizar voz, basta con correr el nodo `soundplay_node` y publicar un mensaje de tipo `sound_play/SoundRequest` con lo siguiente:
 - ▶ `msg_speech.sound = -3`
 - ▶ `msg_speech.command = 1`
 - ▶ `msg_speech.volume = 1.0`
 - ▶ `msg_speech.arg2 = "voz a utilizar"`
 - ▶ `msg_speech.arg = "texto a sintetizar"`

- 1 Ejecutar el comando `roslaunch bring_up speech_test.launch`
- 2 Ejecutar el comando `roslaunch speech_syn speech_test.py "my first synthesized voice"`



- Las voces se pueden instalar con `sudo apt-get install festvox-<voz deseada>`
- Para ver qué voces se tienen instaladas: `ls /usr/share/festival/voices/english/`

- 1 Instalar alguna voz.
- 2 Verificar el nombre de la voz en el directorio `ls /usr/share/festival/voices/english/`
- 3 Modificar el archivo `catkin_ws/src/speech_syn/scripts/speech_test.py` y cambiar la voz a utilizar en el mensaje `SoundRequest`.
- 4 El nombre de la voz se compone de `voice_` más el nombre que aparece en la carpeta `voices/english`.

- OpenCV es un conjunto de bibliotecas que facilita la implementación de algoritmos de visión computacional.
- Se puede usar con diversos lenguajes: C++, Python, Java.
- En Python utiliza la biblioteca Numpy.
- Las imágenes se representan como matrices donde cada elemento puede ser un solo valor, o bien tres valores, dependiendo de si la imagen está en escala de grises o a color.
- La configuración más común es que cada pixel esté representado por tres bytes.



Son diferentes formas de representar el color.



En segmentación por color se recomienda más usar HSV, pues es más robusto ante cambios en la iluminación.

- OpenCV utiliza la biblioteca Numpy para representar imágenes con matrices
- ROS representa las imágenes usando mensajes de tipo `sensor_msgs/Image` o `sensor_msgs/PointCloud2`.
- Para *traducir* las imágenes entre los diferentes formatos, se utiliza el paquete `cv_bridge` (http://wiki.ros.org/cv_bridge).

La segmentación de una imagen se refiere a obtener regiones con ciertas características. En este caso, que estén en un cierto intervalo de color. Los pasos generales para esto son:

- ➊ Transformación de la imagen del espacio BGR al HSV (función `cvtColor`)
- ➋ Obtención de aquellos píxeles que están en un rango de color (función `inRange`)
- ➌ Eliminación de *outliers*, generalmente con operadores morfológicos (funciones `erode` y `dilate`)
- ➍ Obtención de la posición de la región (funciones `findNonZero` y `mean`)

- ➊ Ejecutar el comando `roslaunch bring_up robotino_simul.launch`
- ➋ Ejecutar el nodo `rosrun vision color_segmentation.py`
- ➌ Utilizando la ventana “Image BGR”, obtener una captura de pantalla, guardarla y abrirla con cualquier editor de imágenes (Kolour Paint, por ejemplo) para obtener los valores HSV de la taza o de la lata de Cola-Cola.
- ➍ **Nota:** En OpenCV, los valores de *Saturation* y *Value* se almacenan como valores entre 0 y 255. El valor de *Hue* es un ángulo y suele calcularse en grados, sin embargo, puesto que 360 no puede expresarse con 8 bits, OpenCV almacena la mitad del ángulo en el canal *Hue*.
- ➎ Modificar el archivo `catkin_ws/src/vision/scripts/color_segmentation.py`, en la función `inRange`, para segmentar correctamente la taza verde o la lata de Coca-Cola. Revisar la documentación en línea de dicha función (https://docs.opencv.org/3.4/da/d97/tutorial_threshold_inRange.html).

- La transformada SIFT (Scale Invariant Feature Transform) es un algoritmo para obtener puntos característicos y sus descriptores sin que estos se vean afectados por la rotación o la escala.
- Esta transformada ya viene implementada en OpenCV
(https://docs.opencv.org/master/da/df5/tutorial_py_sift_intro.html)
- Es muy útil cuando los objetos a reconocer son ricos en texturas (bolsas de frituras, latas de refresco, etc)
- Si los objetos son lisos (platos, tazas, cubiertos), conviene más usar segmentación por color o forma.

El proceso general para entrenar, y posteriormente, reconocer un objeto, es el siguiente:

Entrenamiento:

- 1 Tomar una foto del objeto aislado. Esta foto servirá como patrón.
- 2 En OpenCv, crear un objeto de tipo `xfeatures2d.SIFT_create` y mediante la función `detectAndCompute` obtener un conjunto de puntos característicos y sus descriptores.
- 3 Almacenar dichos puntos y descriptores en un archivo. Puede ser binario, yaml, json, etc. En este curso se usará Json.

Reconocimiento:

- 1 Cargar los puntos y descriptores del objeto que se desea reconocer. Estos serán los valores *train*.
- 2 En OpenCv, crear un objeto de tipo `xfeatures2d.SIFT_create` y mediante la función `detectAndCompute` obtener un conjunto de puntos característicos y sus descriptores de la imagen de prueba. Estos serán los valores *query*.
- 3 Comparar los valores *train* con los valores *query* y obtener el subconjunto de valores *query* que más se parece al conjunto *train*. Si la diferencia es menor que un umbral, se puede considerar que el objeto entrenado está presente en la escena.
- 4 Esta comparación se puede hacer con la función `knnMatch` de la clase `FlannBasedMatcher`.

- 1 Ejecutar el comando `roslaunch bring_up robotino_simul.launch`
- 2 Ejecutar el nodo `roslaunch vision sift_detection.py`
- 3 Tomar una captura de la ventana Image BGR y editarla para obtener una imagen como la de la figura, ya sea de la taza verde o la lata de Coca-Cola. El nombre del archivo no debe tener espacios.



- 4 Ejecutar el comando `roslaunch vision sift_training.py _object_name:=<NombreArchivo>`. El nombre del archivo es el de la imagen editada en el punto anterior sin extensión.
- 5 Verificar que el archivo `.json` se haya generado correctamente. Este debería estar en la carpeta `catkin_ws/src/vision/training`.

- ❶ Ejecutar el nodo `roslaunch vision sift_recognition.py _object_name:=<NombreArchivo>`
- ❷ Verificar el correcto reconocimiento. Si no se logró, realizar uno de los siguientes ajustes:
 - ▶ Modificar el umbral en la línea 37 de archivo `sift_recognition.py`,
 - ▶ O la más recomendable: tomar otra captura y volver a entrenar.

- Máquinas de estados.
- Sistemas expertos, implementados con lenguajes lógicos como Prolog o CLIPS.
- Métodos probabilísticos, como MDPs.

Para las pruebas de @Home Beginners, las máquinas de estados son la mejor opción.

Hacer programa para obedecer un comando de navegar a un lugar y buscar un objeto.